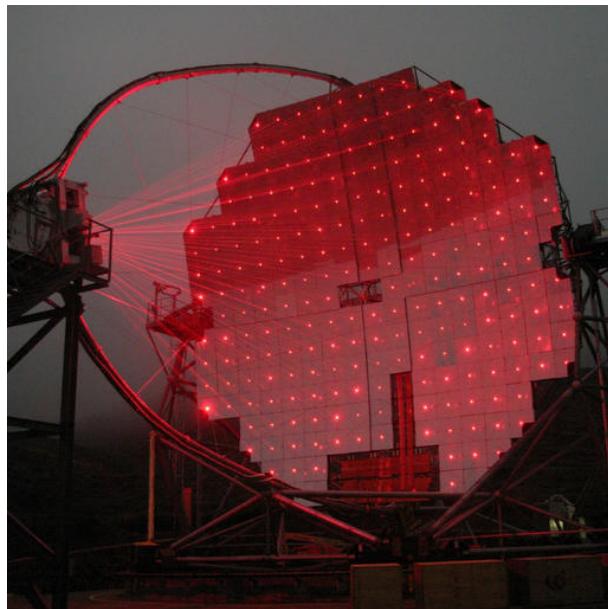


Étape de pré-traitement pour télescope via machine learning



Projet de semestre présenté par

Yannis Perrin

**Informatique et systèmes de communication avec orientation
Développement Logiciel**

Août, 2024

Professeur-e HES responsable

Andres Upegui

Mandant

UNIGE

Légende et source de l'illustration de couverture : Calibration automatique des miroirs de l'IACT MAGIC pendant la nuit. Source : commons.wikimedia.org par Robert Wagner, 2004

TABLE DES MATIÈRES

Remerciements	v
Résumé	vi
Liste de acronymes	vii
Liste des illustrations	ix
Liste des tableaux	x
Introduction	1
1 Chapitre 1 : Phénomène physique	3
1.1 La lumière Cherenkov	3
1.2 Méthodes de détection	4
1.3 Astronomie gamma existante	5
a INTEGRAL	5
b Fermi-LAT	6
c MAGIC	7
d H.E.S.S.	7
e VERITAS	8
f HAWC	8
1.4 Astronomie gamma future	9
a CTAO	9
2 Chapitre 2 : Historique du projet	11
2.1 Projet initial	11
a NUSES	11
b Terzina	12
2.2 Proposition de projet par l'UNIGE	14
2.3 Délais de production	14
2.4 Adaptation du projet	15
a CTLearn	15
a.1 Data levels	16
a.2 Flux logiciel	17
3 Chapitre 3 : Méthodologie	18
3.1 Machine learning	18
3.2 Réseaux neuronaux	18
a Les perceptrons	19
b Multi Layer Perceptron	20
c Apprentissage	20
d Réseau de neurones convolutif	21
e Réseau de neurones récurrents	22
f Auto-encodeurs	23

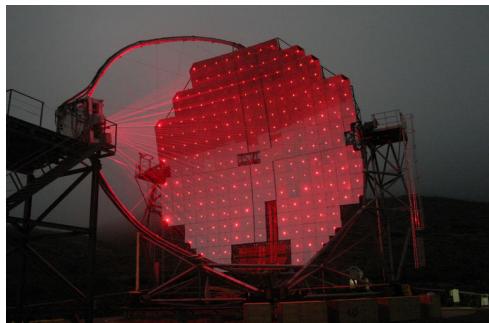
g	Couches	23
g.1	BatchNormalisation	24
g.2	Flatten	24
g.3	Pooling	24
g.4	Dropout	24
3.3	Données	25
a	pe extractor	25
b	Fichiers de simulation Corsika	26
4	Chapitre 4 : Résultats	28
4.1	Gestion des données	28
a	Pe Extractor	28
b	Fichiers de simulation Corsika	29
c	Séparation des données en fenêtres coulissantes	32
d	Création de dataset	33
4.2	Prototypage	33
Conclusion	36	
Bibliographie	36	

REMERCIEMENTS

Je tiens à remercier ma famille pour son support pendant toute la durée de mes études universitaires. Je remercie aussi M. Andre Upegui Posada, Matthieu Heller et Tjark Miener pour leur collaboration technique tout au long de ce projet.

RÉSUMÉ

La lumière Cherenkov est un phénomène physique similaire à un boom supersonique dans le domaine électromagnétique. Lorsque des particules chargées entrent dans notre atmosphère à la vitesse de la lumière, elles démarrent une réaction en chaîne produisant une pluie de lumières atmosphérique. L'observation de ces pluies nous permet de mieux comprendre les mécanismes de la physique de particules. Dans cette optique, l'UNIGE travaille sur la mission pionnière du satellite NUSES et du télescope spatial Terzina. Ce télescope a pour but de détecter et d'étudier les neutrinos de manière indirecte en observant le limbe de la terre et en y détectant des pluies de lumières atmosphériques de gamme d'énergie supérieure à 100PeV. Le but principal de ce projet est d'aider à pallier le problème technique de la bande passante disponible. À cause de ressources limitées à bord du satellite, Terzina n'aura qu'accès à 40 Gbit de transmission par jour et cela ne suffirait pas à transmettre tous les évènements détectés en une journée. La solution imaginée est de créer un réseau de neurones capable d'aider à la décision d'évènements d'intérêt. Il a aussi été imaginé d'utiliser ce même réseau neuronal pour compenser la dégradation des capteurs à bord. Lors de ce travail j'ai commencé par prendre en main les différents simulateurs de données existants suivi de recherches pour comprendre le phénomène physique. Ensuite, j'ai utilisé ces simulateurs pour tester des réseaux de neurones convolutifs. Et pour finir j'ai établi une liste de tâches restantes pour prouver l'efficacité et l'utilité d'un tel réseau de neurones.



Candidat-e :

YANNIS PERRIN

Filière d'études : ISC

Professeur-e(s) responsable(s) :

ANDRES UPEGUI

En collaboration avec : UNIGE

Travail de bachelor soumis à une convention de stage
en entreprise : non

Travail soumis à un contrat de confidentialité : non

LISTE DE ACRONYMES

ASIC Application Specific Integrated Circuits. 13, 14, 15

CERN Conseil Européen pour la Recherche Nucléaire. 26

CTAO Cherenkov Telescope Array Observatory. 9, 15, 16

EM Électromagnétique. 3, 4, 5

ESA European Space Agency. 5

FPGA Field Programmable Gate Arrays. 13, 14, 15

HEPIA Haute École du paysage, d’ingénierie et d’architecture de Genève. 11, 14

IACT Imagin Athmospheric (or Air) Cherenkov Telescope. 7, 9, 36

INFN Istituto Nazionale di Fisica Nucleare. 11

LE Low Energy. 5, 11

LEO Low Earth Orbit. 12

LST Large-Sized Telescope. 9, 10, 15, 26

MST Medium-Sized Telescope. 9, 10

NASA National Aeronautics and Space Administration. 6, 8

pe Photon-Électron. 25, 26, 34, 35

SiPM Silicon Photomultiplier. 12, 13

SST Small-Sized Telescope. 9, 10

UHE Ultra High Energy. 12

UNIGE Université de Genève. 11, 14, 15, 18, 25, 26, 29, 36

VHE Very High Energy. 7, 8

LISTE DES ILLUSTRATIONS

1.1	Advanced Test Reactor core, Idaho National Laboratory	3
1.2	Diagramme de pluies EM et hadroniques	4
1.3	Création de paires	5
1.4	Rayonnement continu de freinage	5
1.5	Illustration du satellite INTEGRAL	6
1.6	Illustration du Fermi Gamma-ray Space Telescope en orbite	6
1.7	Photo des deux télescopes MAGIC	7
1.8	Photo de l'installation H.E.S.S	8
1.9	Fred Lawrence Whipple Observatory	8
1.10	The HAWC Observatory	9
1.11	Rendu 3d de CTAO-North	10
2.1	Mission NUSES	11
2.2	Orbite héliosynchrone de Terzina	12
2.3	Vue de la configuration optique de Terzina	13
2.4	Flux des données CTAO	16
2.5	Flux du logiciel CTLearn	17
3.1	Illustration d'un perceptron	19
3.2	Comparaison de données séparables ou non linéairement	19
3.3	Exemple d'un perceptron multi-couches	20
3.4	Exemple d'une descente de gradient en 3D	21
3.5	Illustration d'une couche convulsive de réseau neuronal	22
3.6	Illustration de réseau de neurones récurrents	22
3.7	Schéma d'auto-encodeur	23
3.8	Illustration du principe de Pooling	24
3.9	Exemple de signal simulé	26
4.1	Exemple de données générées par "pe_extractor"	29
4.2	Structure des fichiers binaires de simulations	30

4.3	Exemple de données générées par simulations Corsika	31
4.4	Données Corsika normalisées	32
4.5	Exemple de séparation des données par fenêtre coulissante	33
4.6	Diagramme de fonctionnement du premier CNN simple	34
4.7	Diagramme de fonctionnement du deuxième CNN à multiple sortie	35

LISTE DES TABLEAUX

1.1	Techniques de détection en fonction de la classification énergétique des rayons gamma	5
1.2	Complementary detection characteristics of imaging air Cherenkov telescopes (IACTs) and extensive air shower arrays.	9

INTRODUCTION

Dans le cadre de mon travail de bachelor, j'ai été choisi pour travailler avec le groupe "High-Energy Multi-Messenger" de l'UNIGE. Ce groupe effectue des recherches expérimentales sur les particules provenant d'astres lointains à l'aide de satellites et de télescopes. Leurs activités se concentrent majoritairement sur les rayons gamma, les rayons cosmiques et les neutrinos. J'ai été mandaté pour les aider à traiter des données concernant les rayons gamma et cosmiques à travers le phénomène physique de la radiation Cherenkov.

Ce phénomène se produit lorsqu'une particule chargée se déplace à une vitesse supérieure à celle de la lumière dans un médium diélectrique transparent. L'exemple le plus notable de ce phénomène est la lumière bleutée produite dans l'eau autour d'un réacteur nucléaire. Cette lumière est due aux rayons gamma produits par la réaction nucléaire. Ces rayons, à cause des immenses forces électromagnétiques, se déplacent momentanément plus rapidement que la vitesse de la lumière dans l'eau. On peut comparer ce phénomène à un boom supersonique mais pour de la lumière.

Les chercheurs de l'UNIGE s'intéressent cependant moins aux rayons gamma produits par des installations humaines qu'aux rayons et particules cosmiques provenant de l'espace. Ces rayons et particules extraterrestres produisent aussi une radiation de Cherenkov mais dans le médium de notre atmosphère. Lorsque le phénomène Cherenkov débute dans l'atmosphère, on appelle cela la "lumière Cherenkov". Ce rayonnement va créer un cône de particules chargées qui sera détecté au sol à l'aide de télescopes.

Aujourd'hui, ce phénomène est déjà étudié par de nombreux télescopes terrestres mais son observation est limitée par divers bruits. Pour pallier à ceux-ci, il est prévu d'étudier ce phénomène depuis un télescope en orbite afin d'éviter ces bruits au maximum. Cependant, le satellite envisagé possède des limitations techniques notamment sur la quantité d'informations qu'il peut envoyer ou recevoir. Mon implication dans ce projet est de présenter un modèle de machine learning qui, en effectuant une étape de pré-traitement, aidera à cibler les événements détectés et, possiblement, réduire la quantité de données à transmettre.

La première partie de ce rapport portera sur une explication du phénomène physique et de la façon dont il est détecté physiquement. Une deuxième partie sur les observateurs existants et l'intérêt d'observer ce phénomène depuis l'espace. Une troisième partie expliquant les tech-

nologies, outils et méthodes utilisées au cours de ce projet. Et, en dernier, les résultats obtenus ainsi que des comptes rend.

CHAPITRE 1 : PHÉNOMÈNE PHYSIQUE

1.1. LA LUMIÈRE CHERENKOV

L'effet Cherenkov a lieu lorsqu'une particule chargée électriquement traverse un milieu diélectrique transparent en excédant la vitesse maximale de la lumière dans ce même milieu. Lors de son passage, cette particule va exciter les autres particules du milieu et produire une réaction en chaîne. Cette dernière va donc créer un cône de particules tel que des électrons, positrons ou photons et même des particules élémentaires nommées hadrons. Cet effet est similaire au bang supersonique lorsque des objets dépassent le mur du son mais dans le spectre électromagnétique. Le cas le plus connu de cet effet est celui qui peut être observé autour des réacteurs nucléaires, dû à la lumière bleue qu'il engendre.

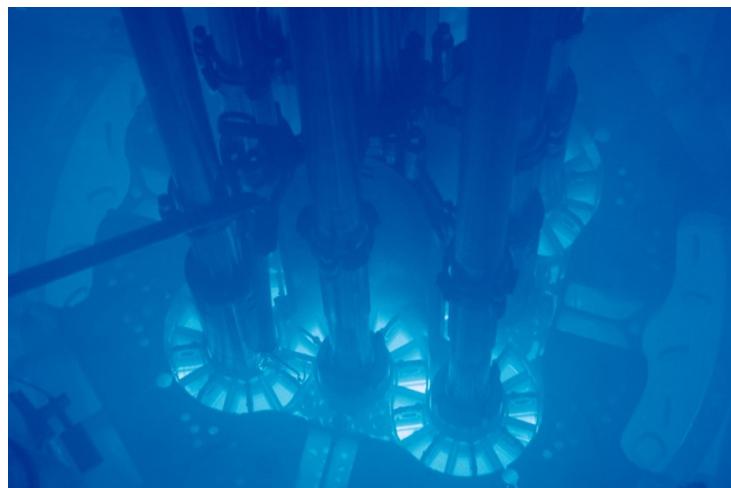


ILLUSTRATION 1.1 – Advanced Test Reactor core, Idaho National Laboratory. Source : [Lab09]

L'intensité de la lumière est communément quantifiée en électron-volt ou eV. Cette unité représente l'énergie cinétique gagnée lorsqu'un électron voit son énergie potentielle augmentée d'un Volt dans le vide.

La lumière Cherenkov atmosphérique peut produire deux types de pluies différentes : les pluies purement Électromagnétique (EM) composées uniquement d'électrons, positrons et photons ainsi que les pluies hadroniques qui elles sont composées de hadrons chargés électriquement, comme des protons.

Les pluies hadroniques sont généralement plus puissantes que des pluies EM et ont voit

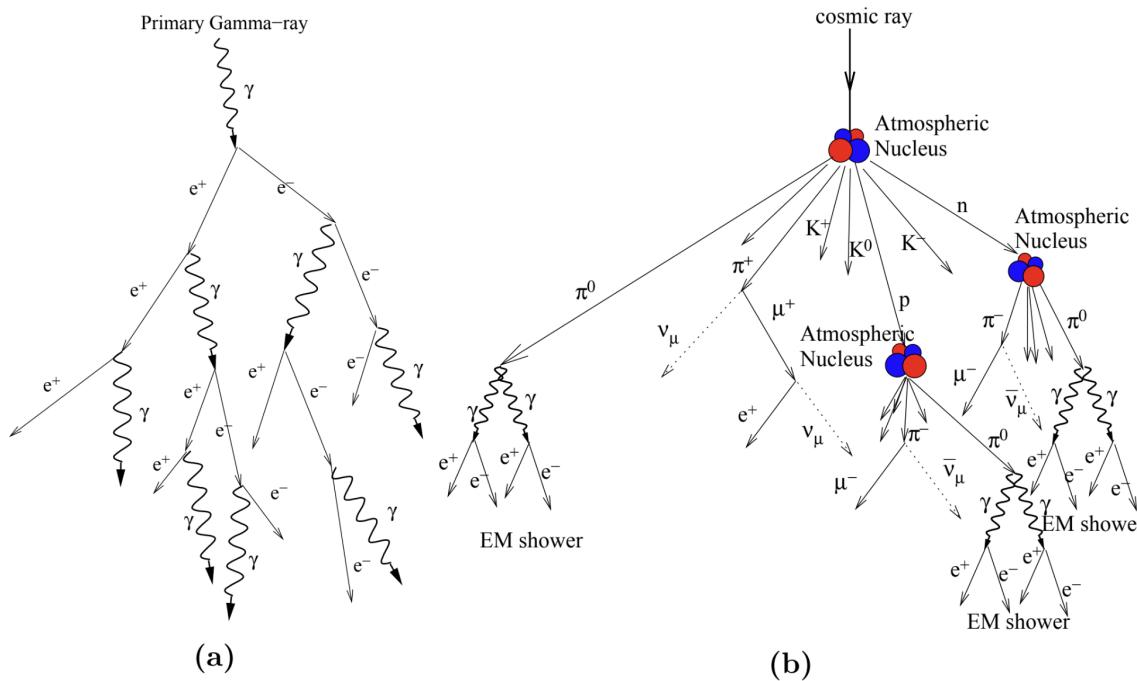


ILLUSTRATION 1.2 – Diagramme de pluies électromagnétiques pures (a) et pluies hadroniques (b). Source : I. Oya Vallejo. “Observation of active galactic nuclei with the Magic telescope”. UCM. PhD thesis. 2010.

aussi qu’elles se décomposent au fur et à mesure en pluies EM. Pour les pluies EM, la production d’électrons et de positrons se fait via deux principes physiques : la production de paires et par rayonnement continu de freinage. La production de paires se produit lorsqu’une particule chargée à haute énergie interagit aux abords du noyau d’une autre particule. Suite à cette interaction un électron et un positron sont produits. Ces deux particules vont ensuite créer à leur tour des photons lorsqu’elles ralentissent autour d’autres noyaux. Ce ralentissement a comme conséquence de produire un photon.

L’intérêt scientifique se porte cependant plus sur les pluies EM pures à cause des rayons gamma qui débutent la réaction en chaîne. Comparés aux particules chargées comme des protons, les rayons gamma eux ne sont pas déviés par les champs électriques ou magnétiques pendant leur trajet à travers les astres. En détectant ces pluies purement EM, on peut en déduire leur provenance beaucoup plus simplement que pour des pluies hadroniques où il faut prendre en compte les différentes interactions astronomiques et atmosphériques.

1.2. MÉTHODES DE DÉTECTION

Les rayons gamma varient grandement en intensité de quelques MeV jusqu’à des dizaines de PeV et plus encore jusqu’au maximum 100 EeV. [Mie23] En fonction de l’énergie d’un rayon

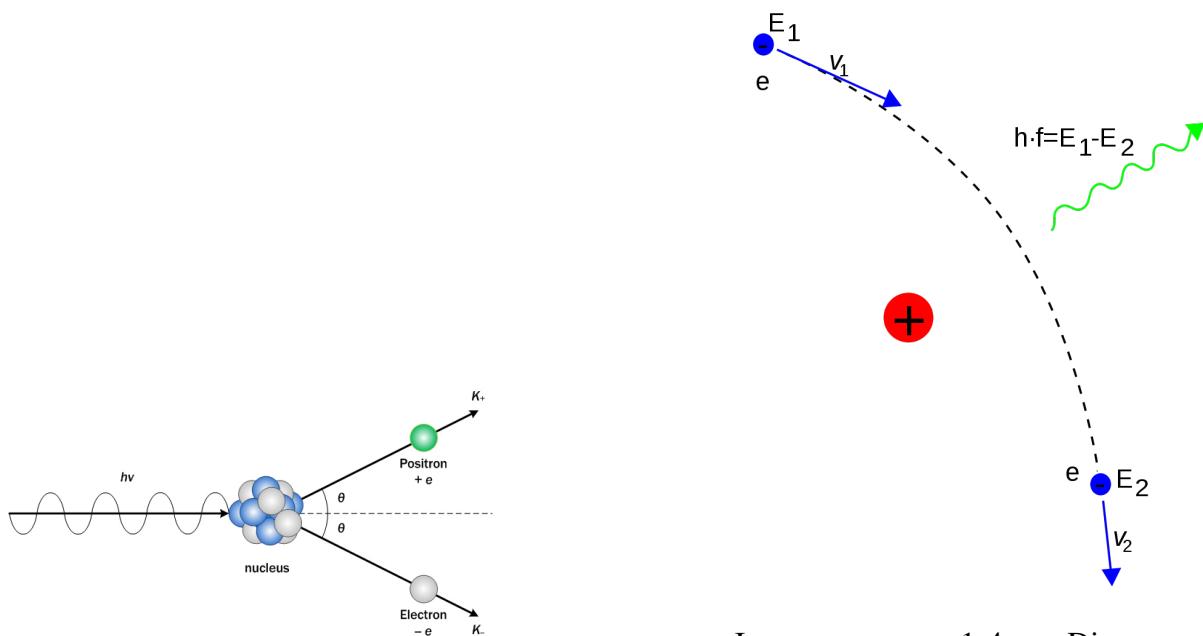


ILLUSTRATION 1.3 – Diagramme de création de paires. Source : [Min24]

ILLUSTRATION 1.4 – Diagramme de rayonnement continu de freinage. Source : [Wik23]

gamma, certaines techniques sont plus optimisées que d'autres, ici on retrouve les différentes techniques utilisées aujourd'hui :

Notation	Gamme d'énergie	Technique de détection	Emplacement
LE	< 30 MeV	Photoélectrique, Compton	Espace
HE	30 MeV à 100 TeV	Création de paires	Espace
VHE	100 GeV à 30 TeV	Cherenkov (atmosphérique)	Terrestre
UHE	30 TeV à 30 PeV	Cherenkov (eau)	Terrestre
EHE	> 30 PeV	Fluorescence, Hybride	Terrestre

TABLEAU 1.1 – Techniques de détection en fonction de la classification énergétique des rayons gamma. Source : [Mie23] p. 17

1.3. ASTRONOMIE GAMMA EXISTANTE

a. INTEGRAL

En l'an 2002, l'European Space Agency (ESA) a lancé le satellite INTEGRAL qui est le premier à avoir observé les spectres EM visible, x-ray et gamma en simultané. Concernant les rayons gamma, ce satellite est équipé de deux capteurs englobant la plage de rayons gamma Low Energy (LE) de 15keV à 10MeV [All22]

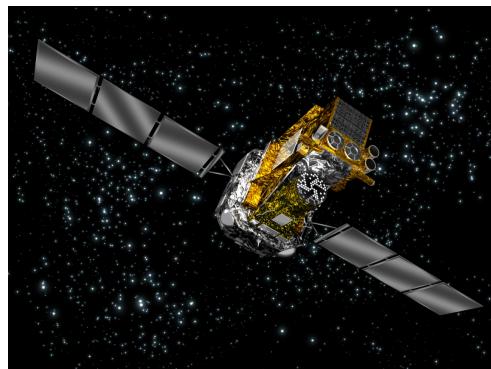


ILLUSTRATION 1.5 – Illustration du satellite INTEGRAL. Source : [Age02b]

b. Fermi-LAT

Le satellite Fermi a été développé par la National Aeronautics and Space Administration (NASA) en collaboration avec des institutions françaises, allemandes, japonaises, italiennes et suédoises. Il a été envoyé en orbite en 2008 et il est en opération depuis lors. [AA24] Il transporte deux instruments de mesures : le Large Area Telescope (20 MeV à > 300 GeV) et le Gamma-ray Burst Monitor (8 keV à 40 MeV).

Le détecteur fonctionne via la détection de production par paires à l'intérieur du détecteur après une collision d'un photon. Les trajectoires et l'énergie dégagée par cet impact ressemble aux expériences des accélérateurs de particules.

L'observatoire fonctionne normalement en un mode de découverte qui scanne tout le spectre gamma du ciel. Il est capable de scanner l'entièreté du ciel en seulement deux orbites. Il a par exemple découvert les bulles de Fermi qui sont d'immenses sources de rayons gamma dans notre Voie lactée. Celles-ci proviendraient de grandes décharges d'énergie émises par le trou noir central de la galaxie il y a de cela plusieurs millions d'années.



ILLUSTRATION 1.6 – Illustration du Fermi Gamma-ray Space Telescope en orbite. Source : [AA23]

c. MAGIC

MAGIC est une installation de deux télescopes **Imagin Athmospheric (or Air) Cherenkov Telescope (IACT)** complétée en 2009 à l'observatoire "Observatorio del Roque de los Muchachos" situé à La Palma aux îles Canaries à une altitude d'environ 2200m. [Gronda]

Les télescopes ont été conçus pour étudier les rayons gamma **Very High Energy (VHE)** de 30GeV à 100 TeV grâce à leurs miroirs de 17m de diamètre qui réfléchissent la lumière dans une grille hexagonale de 1039 tubes photomultiplicateurs, ce qui leur permet de visualiser le ciel avec un champ de vision du ciel de 3,5°.



ILLUSTRATION 1.7 – Photo des deux télescopes MAGIC. Source : [Grondb]

d. H.E.S.S.

Le **High Energy Stereoscopic System** était initialement une installation de 4 télescopes de 12m formant un carré de 120m de côté rendu opérationnel en 2004 dans la région de Khomas en Namibie. En 2012, un 5ème télescope de 28m et 580 tonnes a été ajouté au centre de ce carré, augmentant la sensibilité en la résolution angulaire du système. [Hof12]

Les quatre télescopes aux extrémités ont un champ de vision de 5° et sont équipés de caméras composées de 960 tubes photomultiplicateurs. Le télescope central possède aussi une caméra composée de 2048 photomultiplicateurs avec un champ de vision de 3,2°.



ILLUSTRATION 1.8 – Photo de l’installation H.E.S.S. Source : [Kle12]

e. VERITAS

Le **Very Energetic Radiation Imaging Telescope Array System** est un projet financé par les USA, le Canada et l’Allemagne installé au Fred Lawrence Whipple Observatory dans l’Arizona. Il est composé de quatre télescopes de 12m d’ouverture avec des caméras chacune composées de 499 tubes photomultiplicateurs. [Ver04] L’installation a pour but d’étudier les rayons gamma **VHE** entre 50GeV et 50TeV et a notamment été utilisée pour complémenter la mission Fermi de la NASA.



ILLUSTRATION 1.9 – Fred Lawrence Whipple Observatory. Source : [Ver04]

f. HAWC

HAWC pour **High altitude Water Cherenkov gamma-ray observatory** est un observatoire situé sur le flanc du volcan Sierra Negra au Mexique, à une altitude de 4100 mètres. Comme son nom l’indique, il observe la lumière Cherenkov dans de l’eau au lieu de l’atmosphère. Ceci permet d’étudier des rayons gamma de plus haute intensité, de 100GeV à 100TeV. [Col04]

Au lieu d'utiliser des photomultiplicateurs comme les télescopes précédents, HAWC utilise des compteurs de particules basés sur des scintillateurs. Cette différence de fonctionnement comparé aux IACT lui permet de meilleures performances dans certains domaines tel le champ de vision mais le rend plus sensible au bruit de fond par exemple :

	Télescope Cherenkov	Détecteur de Pluie Atmosphérique
Gamme d'énergie	Basse (<200 GeV)	Haute (>10TeV)
Rejet de bruit de fond	Excellent (>99.7%)	Modéré (>50%)
Champ de vision	Petit (<2°)	Large (>45°)
Disponibilité	Basse (5%-10%)	Haute (>90%)

TABLEAU 1.2 – Complementary detection characteristics of imaging air Cherenkov telescopes (IACTs) and extensive air shower arrays, traduit. Source : [Col04]



ILLUSTRATION 1.10 – The HAWC Observatory. Source : J. Goodman, Nov. 2016 [Col04]

1.4. ASTRONOMIE GAMMA FUTURE

a. CTAO

Le Cherenkov Telescope Array Observatory (CTAO) est le plus grand projet d'observatoire IACT au monde. Il est prévu de construire 60 télescopes répartis sur 2 sites, le premier (CTAO-North) dans l'hémisphère nord aux îles Canaries sur l'île La Palma et le deuxième (CTAO-South) à Paranal, Chili.

L'observatoire est conçu pour étudier les rayons gamma de 20GeV à 300TeV avec plus de 60 télescopes de différentes tailles, Small-Sized Telescope (SST), Medium-Sized Telescope (MST) et Large-Sized Telescope (LST) qui peut atteindre 45m de haut Pour cela chacun des types de télescopes a été conçu pour répondre au mieux à certaines gammes d'énergie. Pour la gamme

principale de l'installation (150GeV à 5TeV), ce sont 23 MST qui sont prévu d'être construire. 37 SST sont prévus et ils seront optimisés pour détecter les énergies > 5TeV et jusqu'à 4 LST sont prévus pour détecter les gammes d'énergie < 150 GeV.



ILLUSTRATION 1.11 – Rendu 3d de CTAO-North. Source : Gabriel Pérez Díaz, IAC [CTA17]

CHAPITRE 2 : HISTORIQUE DU PROJET

2.1. PROJET INITIAL

En novembre 2023, l'Université de Genève (UNIGE) a proposé ce projet de recherche à l'Haute École du paysage, d'ingénierie et d'architecture de Genève (HEPIA), spécifiquement dans le cadre du projet du télescope spatial Terzina. Le but initial de ce projet était de créer un modèle de machine learning permettant d'aider à la décision d'événements scientifiquement intéressants dédiés par le télescope afin de réduire la quantité d'informations transmettre au sol. Le télescope Terzina est prévu d'être lancé à bord du satellite NUSES.

a. NUSES

Le projet **NeUtrino and Seismic Electromagnetic Signals** est une mission spatiale pionnière qui a vu le jour via la collaboration entre différentes universités et organisations gouvernementales. [Tri23] Notamment l'UNIGE, l'Istituto Nazionale di Fisica Nucleare (INFN) et la NASA. Son but est d'envoyer un satellite dans l'espace, avec deux instruments scientifiques à bord, Zirè et Terzina, qui mèneront des expériences une fois en orbite.

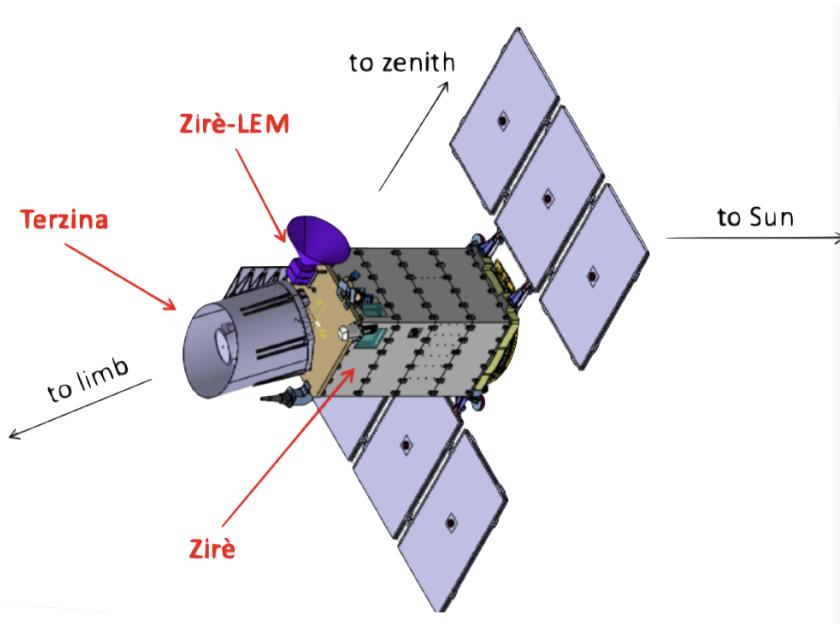


ILLUSTRATION 2.1 – Mission NUSES. Source : [Tri23]

Zirè a pour but d'observer le rayonnement cosmique LE (<250 MeV) pour étudier de plus

près la ceinture de Van Allen, la météo spatiale et les interactions entre les lithosphère, ionosphère et magnétosphère.

Terzina a pour but de tester de manière concrète les technologies qui pourraient être utilisées pour étudier des rayonnements cosmiques **Ultra High Energy (UHE) > 100PeV** et de détecter des neutrinos via les pluies atmosphériques de lumière Cherenkov qu'ils produisent.

Le satellite sera placé en orbite terrestre basse de manière héliosynchrone. L'orbite terrestre basse ou **Low Earth Orbit (LEO)** est définie comme toutes les orbites plus proches que **1000km** au dessus de la surface de la terre.[Age20a] L'orbite héliosynchrone est une orbite presque polaire (naviguant du nord au sud ou inversement) où le satellite passe au dessus d'un même point à la même heure solaire. Cela implique que son orientation en rapport au soleil reste la même.

Pour Terzina, cela permet aux capteurs d'être toujours pointés en direction opposée au soleil pour éviter au maximum les rayons gamma qu'il émet.

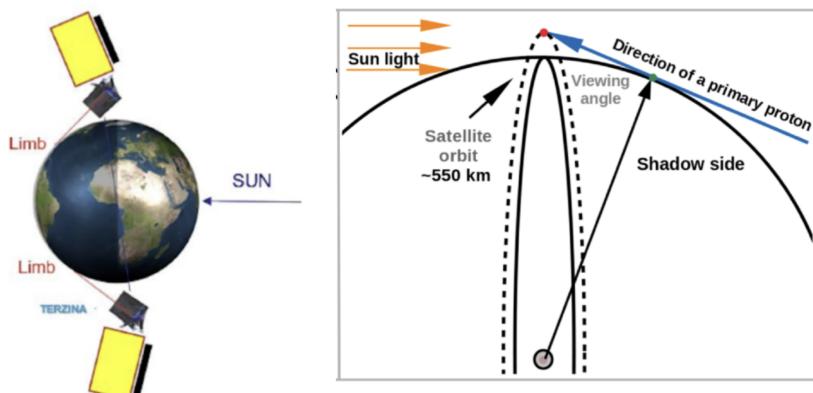


ILLUSTRATION 2.2 – Orbite héliosynchrone de Terzina. Source : [Tri23]

b. Terzina

Comparé aux autres satellites qui ont étudiés des rayons gamma en orbite, Terzina est prévu d'être le premier télescope spatial qui déetectera la lumière Cherenkov depuis l'espace. De plus, il permettra aussi d'étudier les performances de nouveaux capteurs **Silicon Photomultiplier (SiPM)** dans l'espace. Ceux-ci devraient déetecter plus de photons et être plus robustes que leur contrepartie classique bien que ces nouveaux capteurs soient plus **sensible** aux bruits de fond et à l'irradiation abondante hors de notre atmosphère.

Le télescope utilise une configuration à deux miroirs qui redirigent et concentrent les ph-

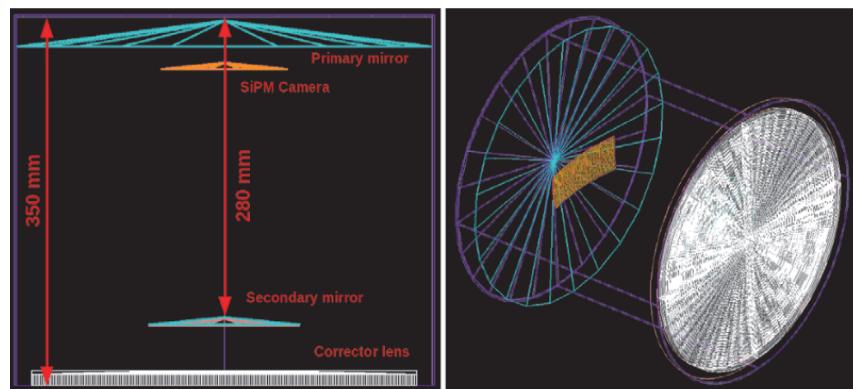


ILLUSTRATION 2.3 – En bleu les miroirs, en blanc la lentille, en orange la caméra et en violet les murs **Gauche** : Vue de dessus. **Droite** : Vue de côté. Source : [Bur23] p.2

tons reçus sur une matrice rectangulaire de 10 modules SiPM, eux-mêmes possédant une résolution de 8x8 pixels, 640 pixels au total. [Bur23]

Cette forme rectangulaire a été décidée pour observer le limbe terrestre de manière optimale et elle est capable de détecter une coupe transversale de $140 \times 360 \text{ km}^2$. Derrière les 10 modules SiPM, il est prévu 10 Application Specific Integrated Circuits (ASIC) chacun possédant 64 canaux pour chacun des tubes photomultiplicateurs de la caméra. Ces ASIC sont conçus pour amplifier le signal de sortie puis le numériser avant d'être collectés par un Field Programmable Gate Arrays (FPGA) à bord du satellite.

En plus de leur rôle de numérisation, les ASIC ont aussi le rôle de déclencheur matériel. Ce rôle est important pour que le signal analogue des photomultiplicateurs ne soit converti en signal numérique que si nécessaire.

 Le premier mécanisme de déclenchement, nommé "haut", arrive lorsque un pic d'énergie dépasse un seuil "haut" dans un seul canal d'un module SiPM ; chaque canal du module est numérisé et collecté par le FPGA.

 Le deuxième mécanisme de déclenchement "bas" arrive lorsque deux pixels adjacents d'un même module SiPM dépassent ce seuil ou lorsque c'est l'un des 8 pixels voisins d'un autre module. Ensuite, les pixels voisins sont analysés pour déterminer si au moins deux d'entre eux ont aussi dépassé ce seuil "bas" ; dans ce cas l'FPGA va conserver cet évènement. Tous ces tests se déroulent dans un laps de temps très court ; de la numérisation du signal au traitement et stockage sur le FPGA, il se passerait environ $51.2\mu\text{s}$

2.2. PROPOSITION DE PROJET PAR L'UNIGE

La quantité de données récoltées par Terzina se révèle être trop importante pour être envoyée au sol, même après l'activation des déclancheurs intégrés au matériel. En effet, la capacité de bande passante de Terzina est limitée à 40Gbit par jour en transmission et seulement quelques Kbit par jour en réception. Ceci est dû à la configuration du satellite NUSES qui est aussi partagé entre les deux instruments Zirè et Terzina.

C'est à ce moment de la conception que l'UNIGE a eu l'idée d'ajouter un réseau de neurones à bord du **FPGA**, capable de filtrer le bruit de chaque pixel pour n'en garder que les photons de pluies atmosphériques. Avec ce signal filtré, la décision d'envoyer ou non l'événement au sol serait plus simple. Ils ont donc proposé ce projet à l'**HEPIA** et j'ai été choisi pour travailler dessus comme projet de semestre.

Les ressources à bord du satellite étant coûteuses, le modèle avait comme contrainte d'être le plus petit possible afin d'utiliser le moins de place et de puissance de calcul. Il est prévu d'utiliser un modèle Keras pour le réseau de neurones, car il existe déjà des moyens de l'exporter vers des **FPGA**. Le déploiement du modèle de réseau de neurones ne faisait pas partie intégrante de ce travail de semestre mais impliquait une restriction technique car la programmation du **FPGA** n'aurait été possible qu'avant le lancement.

En plus de cette utilisation en tant que filtre, l'équipe de l'**UNIGE** a théorisé l'idée que le réseau de neurones pourrait aussi compenser l'usure et l'irradiation des capteurs au fil du temps. Cette compensation pourrait se faire par un ajustement en vol des poids du réseau de neurones ou implicitement par l'architecture et l'entraînement du modèle directement.

2.3. DÉLAIS DE PRODUCTION

Malheureusement, en mars 2023, l'équipe s'occupant du développement des **ASIC** à annoncé des retards de production conséquents ne permettant pas de les installer sur Terzina. Il a donc été décidé de remplacer ces **ASIC** par un modèle déjà existant : CITIROC. Cependant, ces nouveaux **ASIC** ne sont pas capables de transmettre un signal comme les **ASIC** prévus jusqu'à présent et ne donnent que des informations sur le pic d'intensité atteint sur la durée d'**échantillonage**.

Ce changement de matériel modifie les données en sortie du capteur, ne produisant plus de signal numérisé et rendant donc la capacité d'un réseau de neurones difficile voir impossible.

2.4. ADAPTATION DU PROJET

Voyant que l'ajout du réseau de neurones sur le **FPGA** du télescope n'est plus possible, l'**UNIGE** propose alors de poursuivre ce projet de recherche mais pour **utilisation** sur des télescopes au sol. L'équipe de l'**UNIGE** participe également au groupe **CTAO** qui a pour but de créer deux observatoires dotés de trois types de télescopes différents.

Le réseau de neurones imaginé pour Terzina serait aussi utile pour ces télescopes. Les télescopes standard ne présentent pas les mêmes contraintes que la légèreté et la simplicité que Terzina doit respecter pour arriver en orbite. Sans ces contraintes, le **LST** atteint une résolution de 1'855 pixels et une fréquence d'acquisition de **1GHz**. Cette configuration, collecte **24Gbit** de données par seconde avant les systèmes de déclancheurs matériels. [CTA24] De plus, la nouvelle génération de caméra sur laquelle l'**UNIGE** travaille, augmentera même la résolution jusqu'à 8'000 pixels.

L'ajout d'un réseau de neurones capable de réduire le bruit et d'estimer le nombre de photons détectés par pixel serait donc très utile en tant que point de décision supplémentaire pour garder ou non les **diférents** événements déclenchés afin de réduire les ressources utilisées pour le stockage et le traitement de ces données.

De plus, il a été théorisé que le filtrage et l'estimation du nombre de photons que le réseau de neurones apporterait, **puissent** améliorer le traitement des données en aval. Cela pourrait **notamment améliorer** la résolution angulaire (d'où provient la pluie de lumière Cherenkov) et une possible amélioration de la sensibilité du télescope aux événements moins énergétiques.

Pour tester l'amélioration de ces performances, il est prévu d'insérer ce réseau neuronal en tant qu'étape de pré-traitement des données **au pour** chaque pixel avant de les transmettre à un logiciel de classification et d'analyse des pluies Cherenkov : **CTLearn**.

Mais **pour** sa possible utilisation finale, ce réseau pourrait aussi être programmé dans des **ASIC** ou **FPGA** qui seraient intégrés dans les différents télescopes au sol.

a. **CTLearn**

Cet outil, développé en coordination entre **l'université de genève et de Madrid**, permet d'analyser des pluies Cherenkov détectées par les télescopes du **CTAO** afin d'en déterminer son type : hadronique ou électromagnétique, sa provenance dans le ciel et des calculs énergétiques. Ces différentes informations sont ensuite utilisées par d'autres projets pour calculer

d'autres valeurs d'intérêts scientifiques.

a.1. Data levels

Pour faciliter la communication et les échanges entre les nombreuses équipes travaillant pour le CTAO, plusieurs niveaux de données ont été élaborés.

Pipelines : from raw data to source catalogues

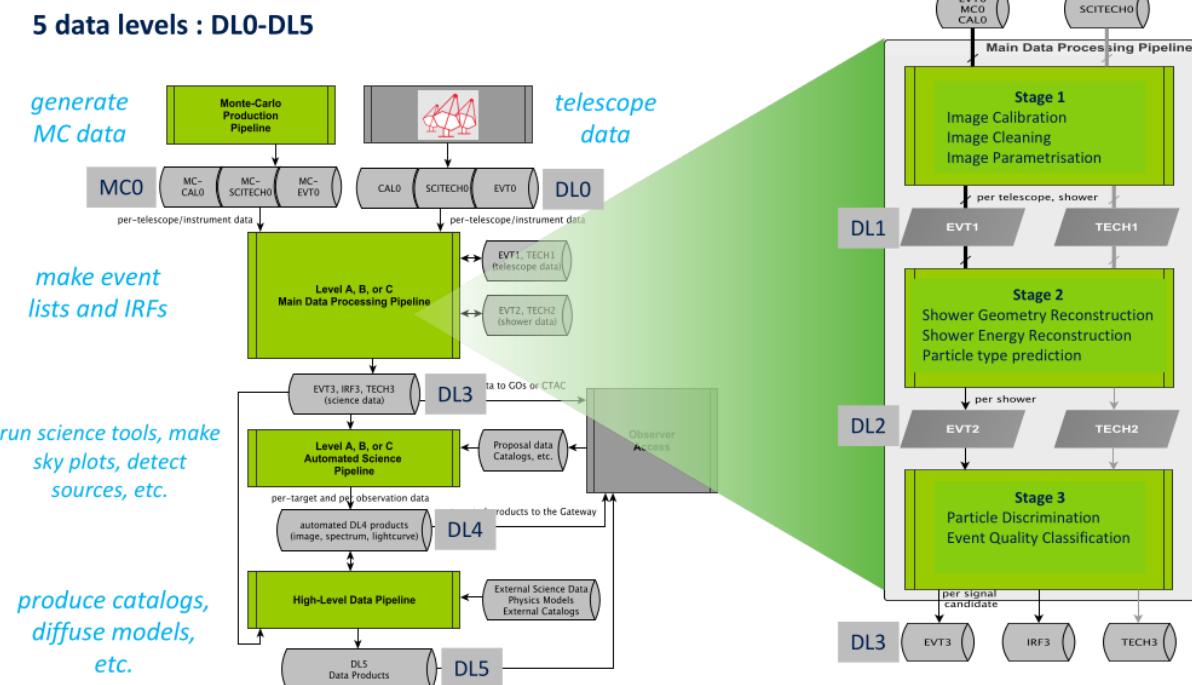
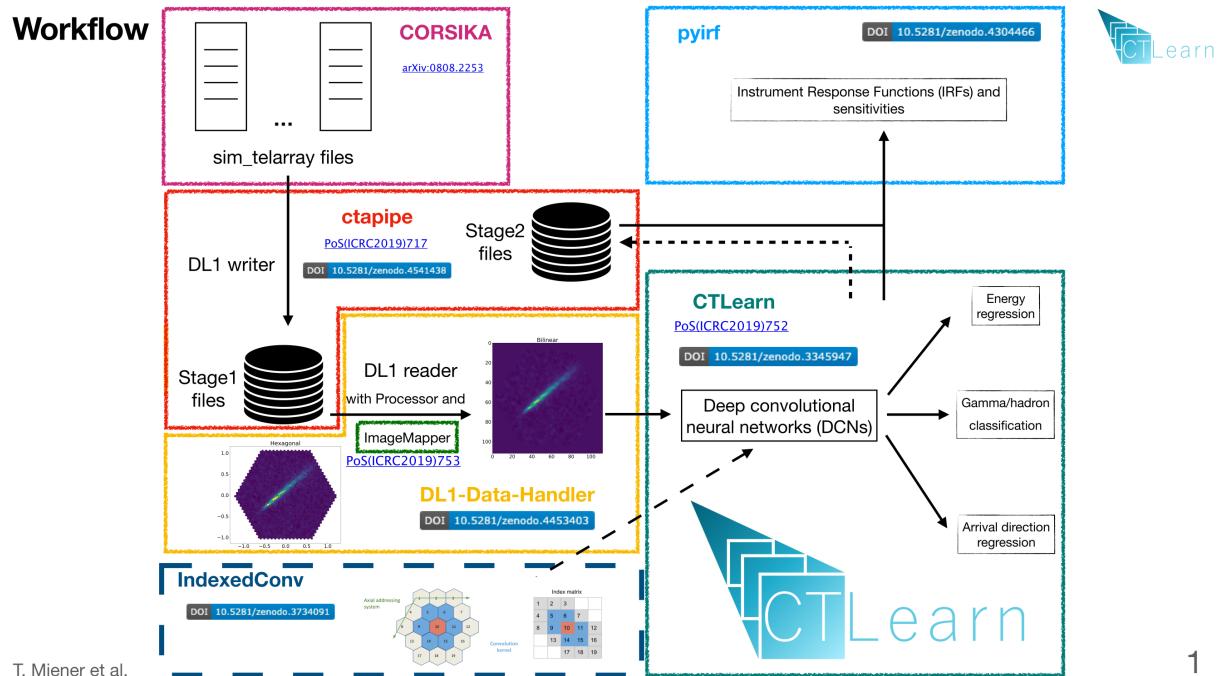


ILLUSTRATION 2.4 – Flux des données CTAO. Source : [CTA22], page 5

- MC0 : Données créées par des simulateurs Monte-Carlo
- DL0 : Données réelles récupérées par les télescopes.
- DL1 : Images calibrées et **nettoyées** (par télescope/pluie Cherenkov)
- DL2 : Reconstruction de la pluie selon les images récupérées et prédition de type hadronique/électromagnétique
- DL3 : Qualification et discrimination des pluies
- DL4 : Analyse des données de haut-niveau (spectres du ciel complet, etc.)
- DL5 : **Aggrégation** des données pour en créer des catalogues en tirer des conclusions

scientifiques.

a.2. Flux logiciel



1

ILLUSTRATION 2.5 – Flux du logiciel CTLearn. Source : [Mie24b]



Les données utilisées par CTLearn sont les signaux numérisées de chaque capteur composant la caméra d'un télescope, données de niveau DL1. Ces données sont récupérées via les outils CTAPipe et DL1-Data-Handler. Ce projet de bachelor résiderait donc entre DL1-Data-Handler et CTLearn ou serait intégré à l'un d'entre eux comme étape de pré-traitement des signaux individuels.

CHAPITRE 3 : MÉTHODOLOGIE

Dans ce projet, nous avons essayé de créer un programme capable d'analyser un signal temporel et d'en estimer la présence et la quantité de photons présent dans ce signal.

Pour cela, nous avons utilisés différents types de réseaux neuronaux qui sont eux-mêmes une technique de machine learning. Ce chapitre se porte donc sur le fonctionnement des technologies et outils utilisés pour ce projet.

3.1. MACHINE LEARNING

Le machine learning peut-être n'importe quel forme de programme ou système capable d'apprendre ou d'améliorer ses performances en fonction des données qu'il traite.

Il existe deux types d'apprentissage pour le machine learning : supervisé et non supervisé. Le premier signifie que les données utilisées pour entraîner un système contient aussi les conclusions qu'il doit en tirer. Par exemple une image et un texte descriptif. Au fur et à mesure d'analyser ces différentes données le système de machine learning va donc y trouver des informations ou patterns auquel il va attribuer les conclusions prédefinies.

Pour l'apprentissage non supervisé, le système de machine learning utilise des données brutes qui n'ont pas de conclusions ou descriptions associées. Ce modèle va alors lui-même essayer de trouver une manière de classifier ou donner un score sur ces données brutes.

Dans le cadre de ce projet, l'équipe de l'UNIGE nous a fournis des données provenant de simulations des capteurs conçus pour les différents télescopes analysés. Lors de la création de ces simulations, les méta-données des photons simulés a aussi été sauvegardée, ce qui nous donne accès à la "vérité" du moment exact où chaque photon a été détecté. Formalisant le corps du projet comme une recherche d'architecture de réseau neuronal avec un apprentissage supervisée.

3.2. RÉSEAUX NEURONAUX

Alors qu'est-ce qu'un réseau de neurones ou réseau neuronal exactement ? Comme vu précédemment, c'est un modèle de machine learning qui est inspiré par le fonctionnement d'un cerveau humain.

Cette technique utilise des noeuds (neurones artificiels) interconnectés entre eux, créant ainsi des couches similiars à nos cerveaux. Chaque noeud peut être ou non connecté à un ou

plusieurs neurones supplémentaires créant une infinité de configuration possible. La configuration d'un réseau de neurones est aussi surnommée comme l'architecture du réseau.

a. Les perceptrons

Chacun des noeuds qui composent un réseaux de neurones fonctionne comme une fonction mathématique, prenant des valuers d'entrée et une valeur de sortie. Ces neurones sont aussi appelé perceptron. Et suivent en général le fonctionnement suivant :

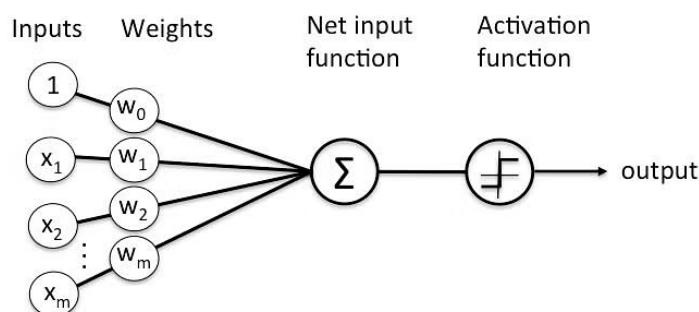


ILLUSTRATION 3.1 – Illustration d'un perceptron. Source : [Ban23]

Les paramètres d'un perceptron sont : un bias, et x données d'entrées avec des poids associés. Toutes ces valeurs pondérées sont ensuite additionnées ensemble et passées à une fonction d'activation qui donnera la valeur finale de sortie au perceptron. En général la fonction d'activation est une sigmoïde, mais pourrait être n'importe quelle fonction mathématique qui s'adapterai mieux au problème que l'on essaye de résoudre.

Avec un seul perceptron, il est possible d'ajuster ces poids de telle manière à lui faire apprendre une motif de séparation linéaire en fonction des données d'entrée.

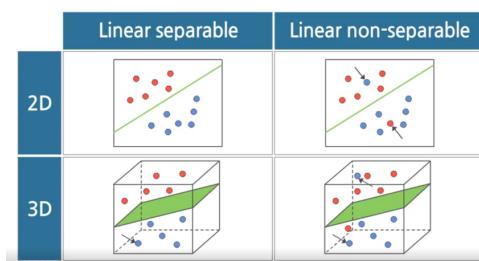


ILLUSTRATION 3.2 – Comparaison de données séparables ou non linéairement. Source : [Rit23]

Il a donc été rapidement imaginé d'interconnecter ces perceptrons pour permettre d'apprendre des problèmes non linéaires. Créant l'architecture la plus simple le "Multi Layer Per-

ceptron" ou perceptron multi-couches.

b. Multi Layer Perceptron

Cette architecture de réseaux de neurones consiste simplement à créer 3 types de couches avec un nombre variable de perceptron pour chacune d'entre-elles :

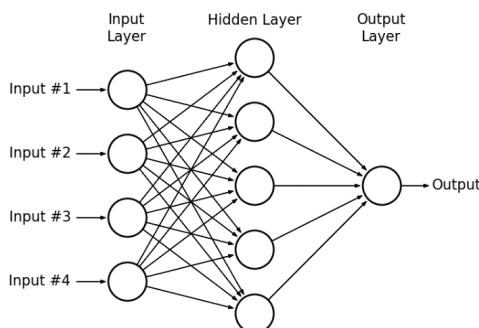


ILLUSTRATION 3.3 – Exemple d'un perceptron multi-couches. Source : [Zah15]

- 1 couche d'entrée : Cette couche représente seulement les valeurs d'entrées de manière organisée, par exemple une image de 10x10 pixels aurait une couche de taille 100.
- x nombre de couches cachées : Ici un nombre de couches indéterminées peuvent être ajoutées. Chacune d'entre elles ont peuvent avoir un nombre de neurones différents dépendant du problème à traiter. d'analyser les
- 1 couche de sortie : Cette couche peut aussi avoir une taille variable dépendant de ce que le modèle doit accomplir. Par exemple si le modèle a comme but de détecter si une image est un chat ou non cette couche pourrait n'avoir qu'un neurone avec une fonction d'activation sigmoïde.



Entre chacune de ces couches, chaque neurone est connecté avec chacun des autres de la couche suivante, créant des couches surnommées "denses".

c. Apprentissage

Peu importe le nombre de couches ou de neurones qui composent un réseau, il faut bien que celui-ci aprenne à résoudre le problème pour lequel il a été conçu. Cet apprentissage se repose sur les bases mathématiques que le perceptron utilise. Lorsque l'on calcule le résultat d'un perceptron celui-ci va en calculer une ou plusieurs valeurs en sortie. Lors d'un apprentissage supervisé, les valeurs de sortie attendues sont connues. On peut en calculer une valeur

d'erreur avec une fonction mathématique. Nous avons donc volonté dans ce cas de minimiser cette fonction d'erreur. Et il est possible de le faire en modifiant les poids des valeurs d'entrées. La manière de trouver comment modifier ces poids s'appelle la descente de gradient.

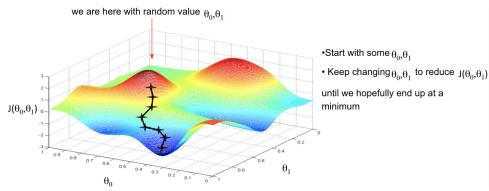


ILLUSTRATION 3.4 – Exemple d'une descente de gradient en 3D. Source : [Liu22]

Il est donc possible de trouver comment modifier les valeurs de chaque poids ou bias de chaque neurones afin de minimiser la fonction d'erreur et cela s'appelle la "backward propagation error" ou "backpropagation".

Un piège fréquent lors de l'entraînement de réseaux neuronaux est l'overfitting. Le processus d'apprentissage fonctionne parfois trop "bien" sur les données utilisées, jusqu'au point où le réseau de neurones à trouver des correspondances ou des motifs qui ne sont pas ceux que l'on recherche. Le rendant hyper spécifié à nos données d'entraînement uniquement.

Par exemple, pour un réseau essayant de différencier des images de chaussures d'autres vêtements. Si, malheureusement, toutes les chaussures sont vertes, le réseau pourrait en déduire que c'est la couleur qui permet de les différencier. Cependant, lorsque le modèle sera présenté une chaussure rouge qui ne faisait pas partie des données d'entraînement celui-ci ne la reconnaîtra pas.

d. Réseau de neurones convolutif

Comme évoqué précédemment, il existe une infinité d'autres configurations pour un réseau de neurones, alors nous ne regarderons en détails que les différentes configurations qui ont été envisagées dans ce projet.

L'une des premières architecture de réseau neuronal qui a été envisagée pour ce projet à été le réseau de neurones convolutif. Celui-ci consiste à certaines couches cachées d'une manière spécifique qui effectuera le même calcul qu'une convolution.

L'opération de convolution en mathématique permet généralement d'extraire des informations d'une image comme le taux de variation d'intensité entre chaque pixel lors d'une détection de contours par exemple. Ici, la différence est que le noyau utilisé pour la convolution n'est pas

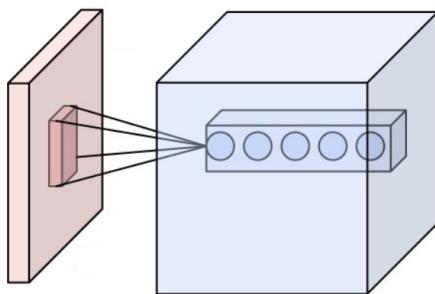


ILLUSTRATION 3.5 – Illustration d'une couche convective de réseau neuronal. Source : [Aph15]

un noyau provenant d'algorithmes comme Sobel ou Canny mais ce sera l'apprentissage du réseau qui va établir un noyau le plus optimisé pour trouver les caractéristiques recherchées dans les données d'entrée.

e. Réseau de neurones récurrents

Un autre type de réseau neuronal est le réseau de neurones récurrents. Cette architecture est adaptée à des problèmes comprenant des données séquentielles ou temporelles généralement comme de la détection automatique de parole ou de texte.

Cette architecture diffère des autres réseaux de neurones car elle contient un mécanisme de "mémoire" intégré dans le modèle. La mémoire est généralement implémentée en connectant sortie du premier neurones comme une entrée supplémentaire à la couche cachée du deuxième neurone.

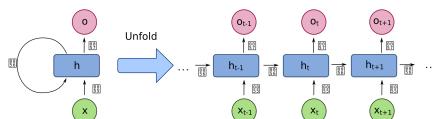


ILLUSTRATION 3.6 – Illustration de réseau de neurones récurrents. Source : [fde17]

Cette "mémoire" n'existe donc que de manière temporaire à chaque exécution du réseau. Certains autres configuration comme les LSTM pour "Long and Short Term Memory" sont aussi capable de se souvenir sur un plus long terme.

f. Auto-encodeurs

Lors de la première partie de ce projet se focalisant sur les problématiques du télescope Terzina, un autre type de réseau avait été envisagé pour sa capacité à compresser des données : les auto-encodeurs.

L'auto-encodeur est une architecture de réseau de neurones particulière qui comprend deux parties distinctes d'encodage et de décodage. Ces deux étapes peuvent aussi être perçues comme une compression et décompression successive. [Dav23]

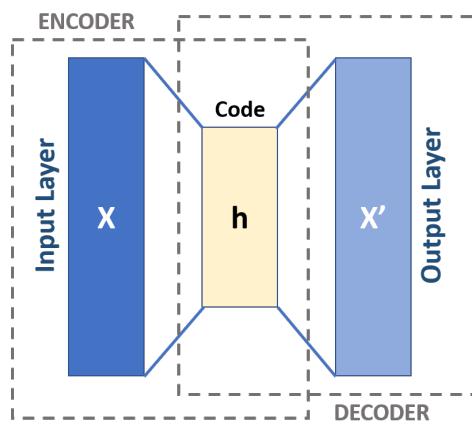


ILLUSTRATION 3.7 – Schéma d'auto-encodeur. Source : [Mas19]

En entraînant le réseau de neurones, celui-ci va apprendre à réduire les informations en entrée jusqu'à un minimum pour ensuite essayer de reproduire au mieux les données originales à partir de cette représentation réduite. Ceci résulte en général en une perte de précision des données lors de la compression.

g. Couche

Les configurations vues jusqu'à maintenant peuvent aussi être combinées entre elles pour former de plus grand réseaux de neurones. Les réseaux neuronaux peuvent donc avoir une partie de réseau CNN et RNN, etc. Chacune des couche peut-ainsi être catégorisée par rapport à son utilité. Il existe aussi plus de couches spécifiques capable de travail spécifique. En voici plusieurs utilisées au cours de ce travail ainsi que leur utilité :

g.1. BatchNormalisation

La couche "BatchNormalisation", en général utilisée en premier dans un réseau, sert à normaliser les données qui lui sont données. Cela sert à généraliser le reste du traitement du réseau, par exemple si l'on traitait des images avec des expositions différentes.

g.2. Flatten

Lors de l'utilisation de couches de convolution, il est possible d'en effectuer plusieurs en même temps et de les traiter parallèlement. On peut ensuite utiliser une couche "Flatten" pour rassembler ces données en une seule dimension.

g.3. Pooling

Ce type de couche dans un réseau neuronal permet de réduire le nombre de dimensions qui lui sont données en entrées. Ses utilités sont de réduire la quantité de calculs suivant cette couche et ~~réduit~~ l'overfitting lors de l'entraînement.

Les deux manières les plus communes pour effectuer un pooling est de garder la moyenne ou le maximum de chaque dimension :

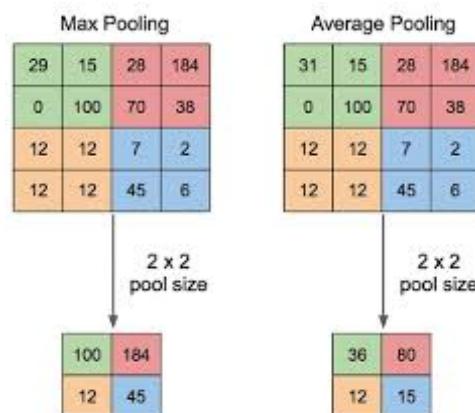


ILLUSTRATION 3.8 – Illustration du principe de Pooling. Source : [Yan19]

g.4. Dropout



Cette couche sert une même utilité que le Pooling en réduisant le nombre d'entrées qui sont passés à la suite du réseau afin d'en réduire l'overfitting. Cependant, ici il ne s'agit pas



de transformation au niveau des dimensions mais une simple gestion de pourcentage qui sera gardée/épurée.

3.3. DONNÉES

Une autre grande partie de ce projet a été la gestion des données utilisées pour tester les différents réseaux de neurones.

a. pe extractor

Le premier simulateur qui a été fourni provenait d'un projet existant de l'[UNIGE](#) s'appelant "pe_extractor". Ce projet Python contient un générateur de signal avec du bruit NSB dans lequel des [photon-électron](#) sont insérés. Le concept de photon-électron ou [Photon-Électron \(pe\)](#) est l'interaction physique lorsqu'un photon est détecté par un capteur et converti en charge électromagnétique analogique. Cette quantité électromagnétique est appelée photon-électron.

Le bruit NSB pour un télescope est le bruit de fond minimum lorsqu'il pointe le ciel pendant la nuit. Même dans [ces meilleures conditions](#), de la lumière provenant des villes et de l'atmosphère est détectée par le télescope. De manière aléatoire et selon une fréquence donnée, le générateur ajoute au signal l'amplitude simulée d'un photon-électron. Cette amplitude est définie par un fichier d'impulsion qui dépend du capteur utilisé.

Le générateur [fournit](#) deux tableaux en sortie : le signal discrétré et des bacs contenant la vérité du nombre de [pe](#) ayant été injectés sur cette période.

Voici les paramètres importants du générateur et leur explication :

1. "pe_rate_mhz" : Définit la fréquence moyenne à laquelle un [pe](#) est injecté dans le signal. L'injection de [pe](#) est aléatoire en suivant une distribution Poisson.
2. "sampling_rate_mhz" : Définit la vitesse d'échantillonnage du signal. Pour Terzina, [cela](#) est de 200MHz.
3. "n_sample" et "n_sample_init" : Le générateur a un mécanisme d'initialisation pour le bruit électrique qui peut prendre un certain nombre de cycles pour commencer à créer des informations cohérentes au niveau physique, ces deux paramètres peuvent donc contrôler un nombre d'échantillons à écarter au début de la génération.
4. "bin_size_ns" : Ce paramètre gère la période de comptabilisation des [pe](#) insérés dans le signal de sortie.

- 5. "shift_proba_bin" : Permet de décaler la comptabilisation de l'insertion de signal par un certain nombre de bacs. Ce système existe car l'impulsion a un temps de montée avant d'atteindre son pic, cela permet de décaler les bacs de vérité pour s'aligner avec le pic de l'impulsion.
- 6. "sigma_smooth_pe_ns" : Ce paramètre sert à répartir le compte des pe insérés sur les bacs voisines en ns pour éviter une vérité entière.
- 7. "noise_lsb" : Est une quantité de bruit électronique.

Les bacs contenant les photons insérés dans le signal bruité à une meilleure résolution que le signal discrétré. Une première adaptation a été programmée pour regrouper ces bacs sur la même fréquence d'échantillonage du signal :

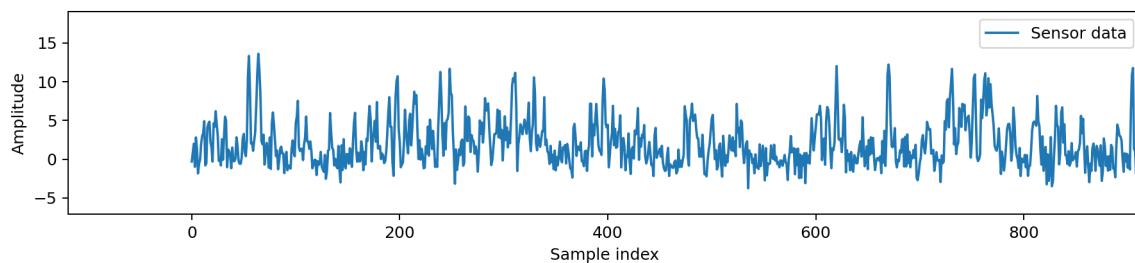


ILLUSTRATION 3.9 – Exemple de signal simulé.

b. Fichiers de simulation Corsika

Le premier simulateur de signal provenant de "pe_extractor" ne simule que des interférences de type NSB. Pour se rapprocher des données réelles des caméras, il a été choisi de récupérer des fichiers de simulation de pluies Cherenkov pour le LST.

Ces fichiers de simulations contiennent énormément de données, de la configuration du télescope, jusqu'au impact des photons provenant des pluies Cherenkov. Ceux-ci sont stockés sur le partage de fichiers du cluster Yggdrasil de l'**UNIGE** sous un format de fichier ROOT.

ROOT est un framework logiciel conçu par le Conseil Européen pour la Recherche Nucléaire (**CERN**) pour l'analyse de données et la gestion d'entrées et sorties. Ces types de fichiers sont souvent utilisés pour stocker de manière structurée des données provenant d'expériences scientifiques en tant qu'arbres et tableaux pour réduire l'espace de stockage utilisé par un fichier.

Ces différentes données ne sont pas utilisables directement et doivent être réinterprétées par le logiciel "pyeventio_example" aussi fournis par l'équipe de l'**UNIGE**. Ce projet met à

disposition un exécutable nommé "runana" qui permet de recréer un fichier binaire contenant certaines métadonnées, le signal de chaque capteur composant la caméra du télescope et les instants auxquels les photons provenant de la pluie Cherenkov ont impactés le capteurs.

CHAPITRE 4 : RÉSULTATS

4.1. GESTION DES DONNÉES

La première étape du projet a été de maitriser et formmatter les données des simulateurs.

a. Pe Extractor



Dans un premier temps cela n'a été qu'avec le projet "pe_extractor". Comme évoqué lors du chapitre précedent, la génération des bacs contenant la vérité des photons détectés n'a pas la même fréquence que celle du signal. J'ai donc adapté ces deux fréquences en regroupant les différents bacs sur la même période que le signal :

```

1 # generator variables
2 n_sample = 200000
3 n_sample_init = 0
4 batch_size = 1
5 shift_proba_bin = 30
6 sigma_smooth_pe_ns = 0
7 bin_size_ns = 0.20
8 sampling_rate_mhz = 1000 #200 MHz is the sampling rate of terzina
9 #250 SST1M
10 #1000 LST + MST
11 pe_rate_mhz = 150 # 1 to 150 MHz
12 noise_lsb=4. # 3.5 to 5.5
13 amplitude_gain=16.
14 relative_gain_std=0.05
15
16 # computed variables
17 sampling_period_s = 1 / (sampling_rate_mhz * 1e6)
18 bin_per_sample = ceil(((sampling_period_s) * 1e9) / bin_size_ns)
19
20 # parameters omitted for brevity
21 gen = generator_nsb(...)
22 data = next(gen)
23
24 # data contains in index 0 the configurable batches of the discrete signal
25 # and in index 1 the batches of truth
26 # here we configured only 1 batch, which explains the [1][0]
27 summed_bins = np.sum(data[1][0].reshape(-1, bin_per_sample), axis=1)

```

LISTING 4.1 – Regroupement des bacs de photons insérés, signal_sense.ipynb

Ce qui nous donne le couple de données suivante :

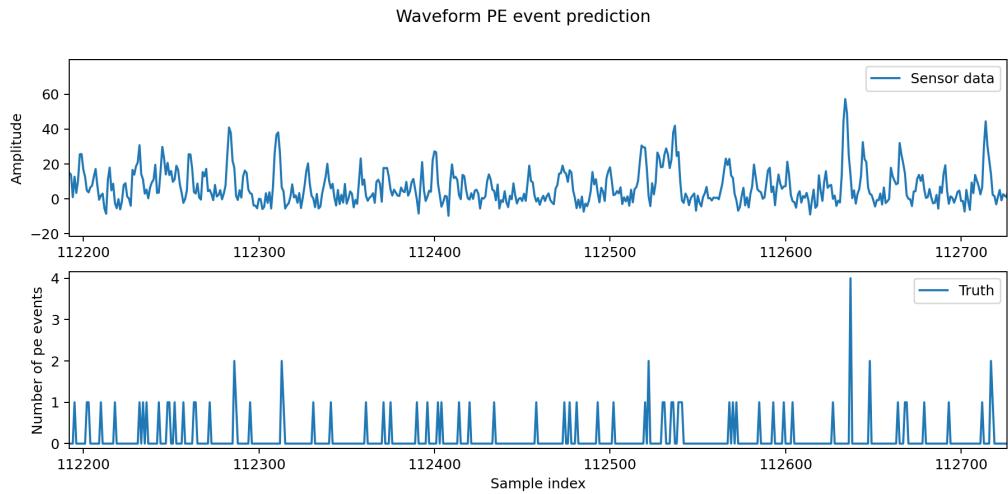


ILLUSTRATION 4.1 – Exemple de données générées par "pe_extractor".

Les configurations des paramètres du générateur sont restés majoritairement les mêmes au cours du projet sauf ceux commentés qui ont évolués au cours du projet, de Terzina aux télescopes terrestres.

b. Fichiers de simulation Corsika

Pour utiliser ces fichiers de simulations, il a d’abord fallu recréer les signaux avec l’outil qui m’avait été fourni par l’UNIGE : "pyeventio_example". Sur le cluster Yggdrasil, j’ai compilé et utilisé l’exécutable "runana" de manière distribuée grâce à un script bash :

```

1  #!/bin/sh
2
3  # manage cluster modules
4  module purge
5  module load GCC/11.2.0  OpenMPI/4.1.1 R0OT/6.24.06
6
7  # select events range to generate
8  ev_start=0
9  ev_stop=1000
10
11 # select the simulation file
12 inRootFiles="/srv/beegfs/scratch/shares/heller/Leonid/mono-lst-sipm-pmma-3ns-v1_triggerless/
13   gamma/0000/corsika_0000ID.root"
14 rndseed="1312312"
15 for ((evID=ev_start; evID<=ev_stop; evID++))
16 do
17   # location of output file
18   binFileOut="/home/users/p/perrinya/scratch/bin_data/gamma_ev$evID.out.bin"
```

```

19      # recreate complete waveform with truths
20      srun --time "00:00:30" /home/users/p/perrinya/pyeventio_example/runana 333 "
21      $inRootFiles" "$evID" "$binFileOut" "$rndseed" &
21 done

```

LISTING 4.2 – Script de génération des signaux à partir de fichier de simulation, data/slurm-run.sh

Les fichiers binaires produits utilisent beaucoup plus de place que les fichiers ROOT. Par exemple, le fichier "corsika_0000ID.root" comportant les informations nécessaires à reconstruire environ 500'000 pluie Cherenkov, d'une durée d'environ 75ns chacune, ne pèse que 1.2GB. En comparaison, les fichiers binaires prennent plus de 2.38GB pour seulement 1000 événements. La totalité des signaux brutes du fichier prendrait une taille de : 500'000/1000 * 2.38GB = 1.19TB

Cependant, ces fichiers binaires ne sont que la première étape pour créer un jeu de données utilisable par nos réseaux de neurones. Ceux-ci sont structurés de la manière suivante :

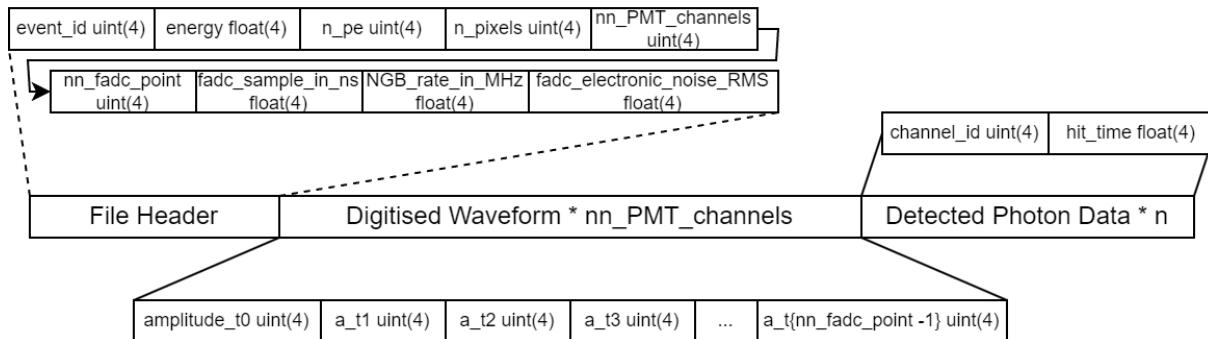


ILLUSTRATION 4.2 – Structure des fichiers binaires de simulations.

J'ai donc du créer un lecteur capable de parser ces fichiers binaires et de recréer une vérité sur la même fréquence que le signal d'entrée. Pour cela, la lecture du header et du signal ce fait simplement en lisant et stockant des variables dans des tableaux en mémoire. Cependant quelques calculs et vérifications doivent être faites pour les photons détectés par la caméra. En premier, il faut convertir l'instant de l'impact en numéro d'échantillon en divisant par la période d'acquisition. Puis il faut vérifier si ce photon a bien été capturé pendant la durée du signal, car ceux-ci peuvent avoir été détectés avant ou après, ceci probablement dû à la gestion de la simulation.

Au final on se retrouve avec des données similaires au premier générateur :

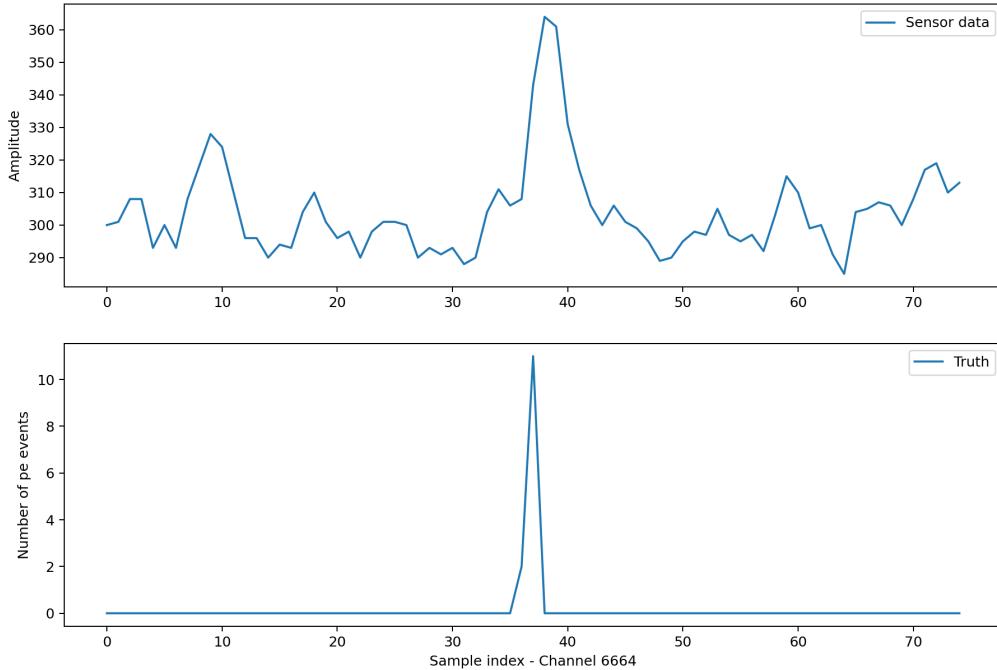


ILLUSTRATION 4.3 – Exemple de données générées par simulations Corsika.

Cependant, même dans cet état, les données ne sont pas encore utilisables. Lorsque l'on regarde l'amplitude du signal contenu dans ces fichiers binaires, ceux-ci sont encodés sur des entiers. Pour réduire ces valeurs avant d'essayer d'entraîner des réseaux neuronaux, il m'a été conseillé de normaliser ces données en les divisant par 8,5 en rapport avec les capteurs utilisés. De plus, nous avons découvert que les temps d'impacts des photons détectés étaient un peu en avance par rapport au signal. Nous avons donc ajouté un délai de 2 échantillons lors du parsing du fichier, pour que les pics de vérité arrivent en même temps ou avec un léger retard pour que le réseau de neurones puisse utiliser les échantillons précédents comme information utile.

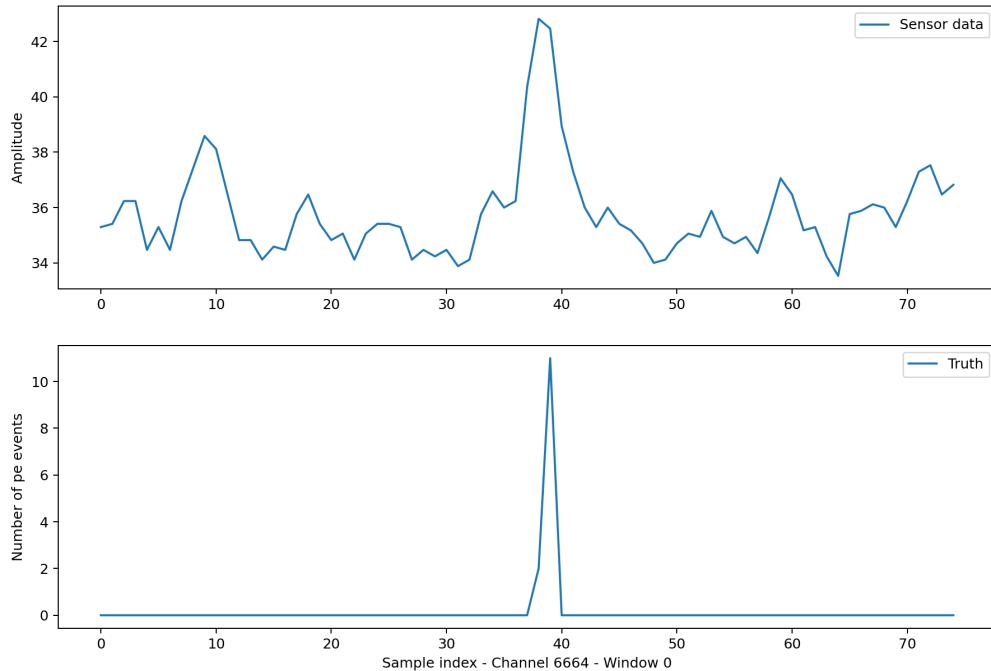


ILLUSTRATION 4.4 – Données Corsika normalisées.

c. Séparation des données en fenêtres coulissantes

Peut-importe la manière utilisée pour générer les données, chacun des ensembles a été séparés en plus petites parties pour les entraînements. Cela pour plusieurs raisons. Au départ, pour Terzina, cela était prévu pour garder le modèle le plus petit possible en limitant le nombre d'entrées utilisées. Cependant, une fois le projet redirigé pour être utilisé au sol, la volonté d'avoir un réseau de neurones capable d'être exécuté en quasi-temps réel pour la latence restait intéressant.

Pour limiter la quantité d'entrées utilisées, il est possible de ne regarder le signal et le tableau de vérité associer partie par partie. Cette technique s'appelle "sliding window" ou fenêtre coulissante, car c'est comme si l'on regardait nos données à travers une fenêtre coulissante que l'on déplace du début à la fin celles-ci :

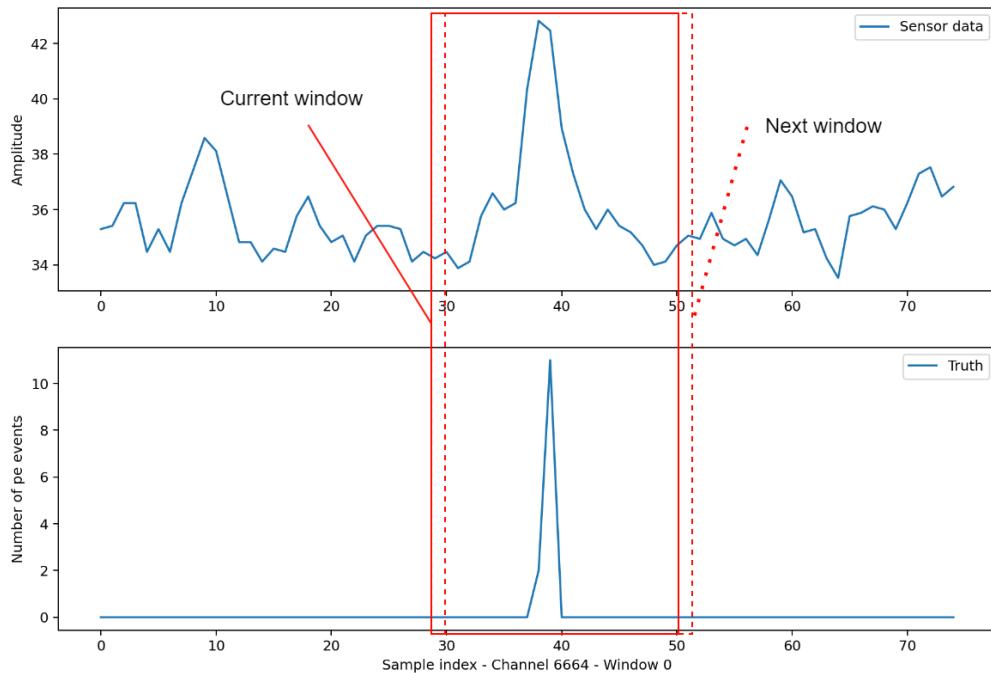


ILLUSTRATION 4.5 – Exemple de séparation des données par fenêtre coulissante.

Cette technique existant déjà il existe une fonction dans la librairie Numpy capable de séparer des données ainsi. Il est quand même important de ne pas séparer le signal de la vérité.

d. Création de dataset

C'est pendant cette même étape de séparation que l'on peut facilement effectuer deux autres actions pour améliorer notre dataset.

La première action, est de séparer nos données en deux. La première partie sera utilisée pour entraîner le réseau tandis que la deuxième ne lui sera jamais montré lors de l'entraînement mais seulement lors d'une étape de validation. Cela dans l'optique d'éviter l'overfitting et valider que le modèle puisse fonctionner sur des données qu'il n'a jamais vu auparavant.

La deuxième action consiste à mélanger le dataset pour éviter de s'entraîner avec des données dans l'ordre, pour pousser le modèle à trouver des motifs dans les données mêmes.

4.2. PROTOTYPAGE

Pour débuter le prototypage, j'ai commencé à mettre en place un réseau neuronal convolutif de régression simple qui prend en entrée une fenêtre de taille fixe, qui contiendra les échantillons

du signal de manière séquentielle dans le temps. Et dont le résultat est une estimation de la probabilité qu'un pe soit présent au centre de la fenêtre analysée :

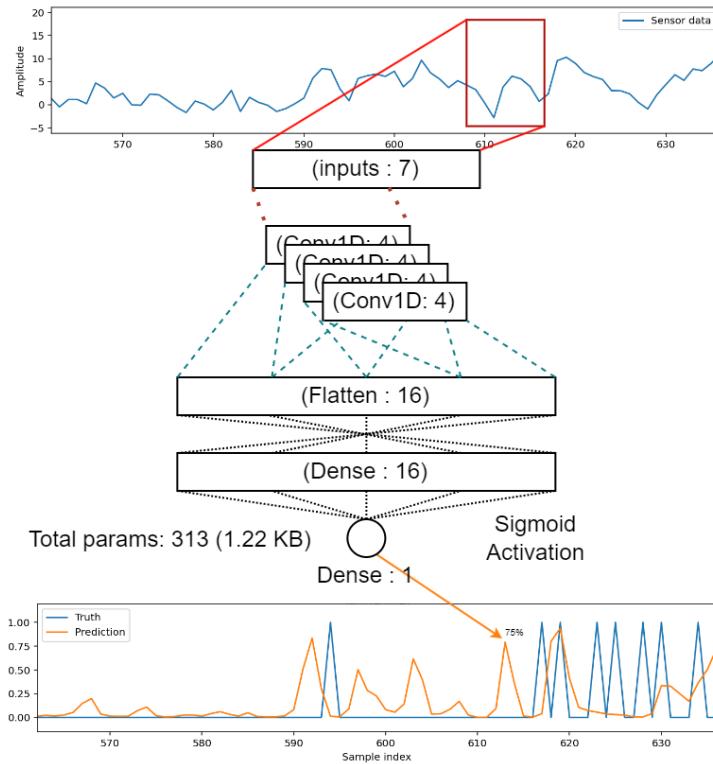


ILLUSTRATION 4.6 – Diagramme de fonctionnement du premier CNN simple.

Le fonctionnement de cette architecture n'a pas donné de bons résultats, ceci à cause de plusieurs facteurs. Le premier est qu'à cause des paramètres de bacs du générateur, les premiers tests effectués se basaient sur des données erronées car les impulsions n'étaient pas centrées au centre de la fenêtre.

Cette première expérience m'a aussi poussé à développer une vue au "cas par cas" où chaque inférence du modèle peut être examinée. Cette vue affiche les données d'entrée, la vérité attendue et le résultat du modèle ce qui permet de confirmer les données d'entraînement de celui-ci.

Cependant, même après avoir corrigé la configuration du générateur, les résultats, bien que légèrement améliorés, restaient non fiables à cause de beaucoup de faux positif et faux négatifs.

Pour palier à cela, au lieu d'entraîner le modèle sur une seule vérité au centre de la fenêtre analysée, ce serait sur chaque échantillon que le réseau neuronal donnera une estimation de la présence ou non d'un pe.

Ce nouveau modèle a immédiatement mieux performé que le précédent :

En modifiant les différents paramètres de chaque couche, il est aussi possible d'améliorer

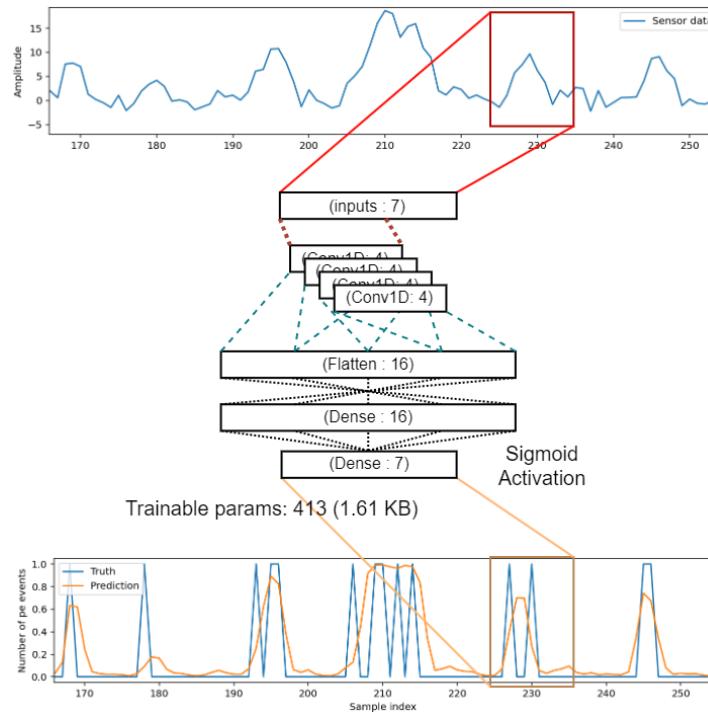


ILLUSTRATION 4.7 – Diagramme de fonctionnement du deuxième CNN à multiple sortie.

les performances de celui-ci. De plus, en ne calculant plus la présence de manière booléenne mais en estimant la quantité de *pe* présents en changeant la fonction d'activation finale pour utiliser la fonction mathématique "ReLU" qui n'est pas confinée à l'intervalle $[0, 1]$ comme la sigmoïde mais à $[0, +\infty[$, il est possible d'entraîner le modèle pour qu'il estime le nombre de *pe* à un instant t dans une fenêtre.

CONCLUSION

Étant passionné par l’astronautique et intéressé par tous les sujets adjacents tels que l’astrophysique ou même l’aéronautique, j’ai été ravi d’être choisi pour participer à un projet concret touchant à ces mêmes domaines.

L’objectif de ce projet de semestre consistait à préparer le développement d’un modèle de réseau neuronal capable d’aider au tri d’évènements capturés par la caméra de Terzina. Il s’est avéré au milieu du projet que les capacités techniques à bord du satellite ne seraient plus capable de produire des données suffisantes pour le réseau neuronal envisagé, mais les résultats préliminaires du projet ont permis à l’équipe de l’UNIGE de voir un potentiel dans la réutilisation d’un tel modèle dans des télescopes IACT terrestres.

La première étape de ce travail a été de comprendre le phénomène physique de la lumière Cherenkov. Cette étape de découverte m’a grandement plu car pendant mes recherches sur le sujet, j’ai redécouvert des sujets dont j’avais déjà entendus parler et ai pu en approfondir mes connaissances.

Dans un deuxième temps, j’ai dû comprendre et faire fonctionner des projets existants pour générer les données sur lesquelles baser mes essais de réseau de neurones. Lors de mes premiers essais, j’ai rapidement rencontré les différents cas bloquants vus dans mes cours de machine learning, notamment les problèmes liés aux format et à la composition des données d’entrée.

Ces différentes étapes m’ont permis d’établir une liste des tâches et de fonctionnalités nécessaires au projet final. Mon projet de bachelor sera donc d’établir des métriques de performance et une série de tests pour pouvoir comparer efficacement les prochains modèles qui seront étudiés lors de la suite de ce projet afin de trouver un ou plusieurs modèle adapté aux attentes de l’équipe de l’UNIGE.

BIBLIOGRAPHIE

- [AA23] National AERONAUTICS et Space ADMINISTRATION. *Fermi Gamma-ray Space Telescope*. <https://science.nasa.gov/mission/fermi>. Accessed : (15.04.2024). 2023.
- [AA24] National AERONAUTICS et Space ADMINISTRATION. *Fermi Gamma-ray Space Telescope*. <https://fermi.gsfc.nasa.gov/>. Accessed : (15.04.2024). 2024.
- [Age02a] European Space AGENCY. *Integral overview*. https://www.esa.int/Science_Exploration/Space_Science/Integral_overview. Accessed : (14.04.2024). 2002.
- [Age02b] European Space AGENCY. *Integral Rendition*. https://www.esa.int/ESA_Multimedia/Images/2001/11/Integral. Accessed : (14.04.2024). 2002.
- [Age20a] European Space AGENCY. *Low Earth orbit*. https://www.esa.int/ESA_Multimedia/Images/2020/03/Low_Earth_orbit. Accessed : (15.04.2024). 2020.
- [Age20b] European Space AGENCY. *Polar and Sun-synchronous orbit*. https://www.esa.int/ESA_Multimedia/Images/2020/03/Polar_and_Sun-synchronous_orbit. Accessed : (15.04.2024). 2020.
- [All22] Lorella Angelini Jesse ALLEN. *Integral Specifications*. <https://heasarc.gsfc.nasa.gov/docs/integral/integral.html>. Accessed : (14.04.2024). 2022.
- [Aph15] Wikimedia Commons APHEX34. *Convolutional layer*. https://commons.wikimedia.org/w/index.php?title=File:Conv_layer.png&oldid=867907596. Accessed : (19.04.2024). 2015.
- [Ban23] Mayank BANOULA. *What is Perceptron : A Beginners Guide for Perceptron*. <https://www.simplilearn.com/tutorials/deep-learning-tutorial/perceptron>. Accessed : (18.08.2024). 2023.
- [Ber24] Konrad BERNLÖHR. *Atmospheric Cherenkov light*. <https://www.mpi-hd.mpg.de/hfm/CosmicRay/ChLight/Cherenkov.html>. Accessed : (21.02.2024). 2024.

- [Bur23] Leonid BURMISTROV. “Terzina on board NUSES : A pathfinder for EAS Cherenkov Light Detection from space”. In : *EPJ Web of Conferences* 283 (2023). Sous la dir. d'I. DE MITRI et al., p. 06006. ISSN : 2100-014X. DOI : 10.1051/epjconf/202328306006. URL : <http://dx.doi.org/10.1051/epjconf/202328306006>.
- [Col04] The HAWC COLLABORATION. *The High-Altitude Water Cherenkov Gamma-Ray Observatory*. <https://www.hawc-observatory.org>. Accessed : (16.04.2024). 2004.
- [CTA17] IAC CTAO Gabriel Pérez Díaz. *CTAO Northern Hemisphere Array Rendering*. https://www.flickr.com/photos/cta_observatory/32835056736/. Accessed : (18.04.2024). 2017.
- [CTA22] CTAO. *5 Concepts You Should Know About Gradient Descent and Cost Function*. https://indico.cern.ch/event/1096028/contributions/4761499/attachments/2404761/4113415/CTA-GDB_2022.pdf. Accessed : (18.08.2024). 2022.
- [CTA24] CTAO. *LST Specifications*. https://www.ctao.org/wp-content/uploads/Specifications_LST_2024.pdf. Accessed : (16.08.2024). 2024.
- [CTAnd] CTAO. *Cherenkov Telescope Array Observatory*. <https://www.ctao.org/>. Accessed : (18.04.2024). n.d.
- [Dav23] IBM DAVE BERGMANN Cole Stryker. “What is an autoencoder ?” In : (2023). Accessed : (19.04.2024).
- [fde17] Wikimedia Commons FDELOCHE. *Recurrent neural network unfold*. https://commons.wikimedia.org/w/index.php?title=File:Recurrent_neural_network_unfold.svg&oldid=854998628. Accessed : (19.04.2024). 2017.
- [Gronda] MAGIC GROUP. *The MAGIC Telescopes*. <https://magic.mpp.mpg.de/>. Accessed : (16.04.2024). n.d.
- [Grondb] MAGIC GROUP. *The MAGIC Telescopes Photo*. https://magic.mpp.mpg.de/gallery/pictures/tn/IMG_2520.JPG.html. Accessed : (16.04.2024). n.d.
- [Hof12] Werner HOFMANN. *The H.E.S.S. Telescopes*. <https://www.mpi-hd.mpg.de/>. Accessed : (16.04.2024). 2012.

- [Kle12] H.E.S.S. collaboration KLEPSER DESY. *The H.E.S.S. II five-telescope gamma-ray experiment in Namibia*. https://commons.wikimedia.org/wiki/File:HESS_II_gamma_ray_experiment_five_telescope_array.jpg. Accessed : (16.04.2024). 2012.
- [Lab09] Argonne National LABORATORY. *Advanced Test Reactor core, Idaho National Laboratory*. www.flickr.com/photos/35734278@N05/3954062594/. Accessed : (10.04.2024). 2009.
- [Liu22] Clare LIU. *5 Concepts You Should Know About Gradient Descent and Cost Function*. <https://www.kdnuggets.com/2020/05/5-concepts-gradient-descent-cost-function.html>. Accessed : (18.08.2024). 2022.
- [Mas19] Michela MASSI. *Autoencoder schema*. https://commons.wikimedia.org/w/index.php?title=File:Autoencoder_schema.png&oldid=808656740. Accessed : (19.04.2024). 2019.
- [Mie23] Tjark MIENER. “Indirect Dark Matter Searches in the Gamma-ray Band and Development of New Analysis Techniques for Ground-based Gamma-ray Astronomy”. Thèse de doct. 2023.
- [Mie24a] Tjark MIENER. *Getting started with DLIDH+CTLearn*. https://commons.wikimedia.org/w/index.php?title=File:Conv_layer.png&oldid=867907596. Accessed : (19.04.2024). 2024.
- [Mie24b] Tjark MIENER. *Getting started with DLIDH+CTLearn*. Support de présentation. 2024.
- [Min24] MIN-KYONG. *Pair Production and Annihilation*. <http://electrons.wikidot.com/pair-production-and-annihilation>. Accessed : (10.04.2024). 2024.
- [Ren20] Yves RENIER. *PE Extractor*. <https://github.com/cta-sst-1m/pe-extractor>. Accessed : (18.04.2024). 2020.
- [Rit23] F. Zanchetta RITA FIORESI. *Deep Learning and Geometric Deep Learning : an introduction for mathematicians and physicists - Scientific Figure on ResearchGate*. https://www.researchgate.net/figure/Linearly-separable-and-linearly-non-separable-sets-githubborg_fig4_370634232. Accessed : (16.08.2024). 2023.

- [Tri23] Caterina TRIMARELLI. *The NUSES space mission.* https://indico.cern.ch/event/1199289/contributions/5446979/attachments/2703059/4692617/NUSES_TAUP.pdf. Accessed : (14.04.2024). 2023.
- [Ver04] VERITAS. *Very Energetic Radiation Imagin Telescope Array System.* <https://veritas.sao.arizona.edu/>. Accessed : (16.04.2024). 2004.
- [Wik23] l'encyclopédie libre. WIKIPÉDIA. *Rayonnement continu de freinage.* http://fr.wikipedia.org/w/index.php?title=Rayonnement_continu_de_freinage&oldid=205544775. Accessed : (10.04.2024). 2023.
- [Yan19] Muhamad YANI. *Application of Transfer Learning Using Convolutional Neural Network Method for Early Detection of Terry's Nail.* https://www.researchgate.net/figure/Illustration-of-Max-Pooling-and-Average-Pooling-Figure-2-above-shows-an-example-of-max_fig2_333593451. Accessed : (19.08.2024). 2019.
- [Zah15] Mohamed ZAHRAN. *ASSESSMENT OF ARTIFICIAL NEURAL NETWORK FOR BATHYMETRY ESTIMATION USING HIGH RESOLUTION SATELLITE IMAGERY IN SHALLOW LAKES : CASE STUDY EL BURULLUS LAKE.* - *Scientific Figure on ResearchGate.* https://www.researchgate.net/figure/A-hypothetical-example-of-Multilayer-Perceptron-Network_fig4_303875065. Accessed : (18.08.2024). 2015.